

Rede neural para previsão do PIB de países da América do Sul

TITO. L. DHAYSE¹, (UFRJ)

¹Universidade Federal do Rio de Janeiro, Rio de Janeiro, RJ 21945-970 BR (e-mail: dhayse@poli.ufrj.br)

ABSTRACT O Produto Interno Bruto é uma medida importante e amplamente utilizada para avaliar o desempenho econômico de um país, já que serve como indicador do crescimento e do bem-estar econômico do mesmo. Além disso, é uma métrica valiosa para auxiliar no planejamento socioeconômico da nação. Com isso, nesse trabalho, há o entendimento dessa importância ao propor o uso de redes neurais artificiais para a previsão do PIB dos países da América do Sul. O objetivo da rede criada é o aprendizado de padrões e relações complexas utilizando dados históricos e conseguir fornecer previsões mais precisas do que os modelos tradicionais, normalmente feita por humanos. Sob tal ótica, foi possível atingir um patamar de aprendizado satisfatório pela rede usando o método de backpropagation em variáveis de entrada cuidadosamente selecionadas no banco de dados escolhido, e seus dados devidamente analisados em diversas fases de pré-processamento, onde foram tratados, selecionados, normalizados e separados em treino, validação e teste. Assim, foi possível obter resultados palpáveis e que podem ser utilizados em diversas aplicações diferentes para o planejamento econômico dos países da América do Sul.

INDEX TERMS Redes Neurais Artificiais, Inteligência Artificial, Economia, PIB.

I. INTRODUÇÃO

PREVER de forma precisa e confiável o PIB é uma questão crítica para o desenvolvimento econômico dos países da América do Sul. Neste contexto, o uso de redes neurais artificiais demonstra-se como uma ferramenta poderosa para alcançar essa previsão, fornecendo uma contribuição direta para o crescimento econômico e a estabilidade da região.

Esse estudo busca explorar o potencial das redes neurais artificiais para estimar o PIB, com ênfase na América do Sul. Ao obter uma boa estimativa do PIB com base nas redes neurais, os resultados deste estudo têm implicações significativas para diversos setores. Notavelmente, a previsão precisa do desempenho econômico futuro torna-se um atrator crucial para investimentos no mercado financeiro. Além disso, torna-se essencial para o planejamento empresarial, permitindo que as empresas antecipem e planejem suas operações, estoques, produções e investimentos com base em uma métrica confiável e atualizada.

Um aspecto relevante é a capacidade dessa previsão em auxiliar na avaliação de políticas econômicas em vigor, fornecendo *insights* sobre seus possíveis resultados, sejam eles positivos ou negativos. Dessa forma, as autoridades governamentais podem tomar decisões mais informadas e direcionadas para impulsionar o crescimento econômico e a estabilidade na região.

Com este trabalho, espera-se contribuir para o avanço do conhecimento na área de previsão econômica utilizando redes neurais artificiais, oferecendo uma abordagem inovadora para impulsionar o desenvolvimento sustentável e o progresso econômico na América do Sul. Ao longo deste artigo, serão apresentados os métodos e dados utilizados, bem como as análises dos resultados obtidos, visando proporcionar uma visão abrangente sobre a aplicabilidade e eficácia dessa abordagem.

O restante deste artigo está organizado de modo que na seção 2 é feito um breve revisão sobre análise econômica e redes neurais. Posteriormente, na seção 3 é apresentado a metodologia do estudo, na seção 4 é feita uma análise dos resultados e, por fim, na seção 5 as considerações finais desse estudo.

II. REVISÃO DA LITERATURA

A. FUNDAMENTOS DE ANÁLISE ECONÔMICA

A análise econômica é um campo fundamental para compreender o funcionamento das atividades econômicas de um país ou região. Seu objetivo é estudar os diversos fatores que influenciam a economia, a fim de fornecer informações valiosas para tomadas de decisões em políticas governamentais, estratégias empresariais e investimentos. Dentre os principais indicadores econômicos, o Produto Interno Bruto (PIB) se

destaca como uma medida-chave para avaliar o desempenho e o crescimento econômico de uma nação.

O Produto Interno Bruto é uma métrica que representa o valor total de todos os bens e serviços produzidos em um país durante um determinado período, geralmente trimestral ou anual. Ele engloba tanto a produção interna de bens e serviços para o consumo doméstico, quanto as exportações líquidas (diferença entre exportações e importações). O PIB é um indicador amplo e abrangente, refletindo a atividade econômica em todos os setores, desde agricultura e indústria até serviços financeiros e tecnologia.

B. REDES NEURAIS MLP

Na análise econômica, as Redes Neurais Artificiais, e mais especificamente as *Multilayer Perceptrons* (MLPs), têm se destacado como uma ferramenta poderosa para a modelagem e previsão de séries temporais econômicas. As MLPs são um tipo de rede neural *feedforward* composta por camadas de neurônios interconectados, onde cada neurônio em uma camada está conectado a todos os neurônios da camada seguinte. Essa arquitetura permite que as MLPs capturem relações complexas entre variáveis econômicas, tornando-as capazes de aprender padrões não lineares nos dados. Além disso, as MLPs possuem a capacidade de se adaptar e aprender a partir de dados históricos, o que as torna ideais para tarefas de previsão econômica. Através de um processo de treinamento utilizando técnicas de otimização, como o algoritmo de *backpropagation*, as MLPs ajustam os pesos das conexões entre os neurônios para minimizar o erro de previsão e, assim, aprimorar a capacidade de generalização do modelo. Essa flexibilidade e capacidade de aprendizado tornam as redes MLPs uma escolha promissora para a previsão do Produto Interno Bruto (PIB) e outras variáveis econômicas importantes, contribuindo significativamente para o avanço da análise econômica e tomada de decisões fundamentadas em cenários complexos.

C. TRABALHOS RELACIONADOS

Nesta seção, destacamos alguns trabalhos relevantes relacionados ao tema de previsão econômica utilizando redes neurais artificiais.

1. No estudo realizado por [1], foi apresentada uma introdução abrangente sobre o uso de redes neurais artificiais na previsão de séries econômicas. O artigo aborda conceitos fundamentais de redes neurais e sua aplicação na análise de dados econômicos, fornecendo uma base teórica para pesquisas posteriores.

2. Em [2], foi proposto um modelo de previsão econômica regional baseado em uma rede neural convolucional profunda e *big data*. O estudo enfoca a análise econômica em nível regional e utiliza uma arquitetura de rede convolucional para capturar padrões complexos nos dados econômicos, resultando em previsões mais precisas.

3. O trabalho de [3] propõe uma abordagem de previsão de tendências de indicadores econômicos em séries temporais, combinando uma rede neural recorrente com indicadores lí-

deres. Essa estratégia visa melhorar a capacidade de previsão ao incorporar informações adicionais de indicadores econômicos importantes.

4. Em [4], os autores exploram o uso da análise de componentes independentes (ICA) e regressão de vetores de suporte (SVR) para a previsão de séries temporais financeiras. Essa abordagem inovadora visa lidar com a complexidade e a volatilidade dos dados financeiros.

5. Em [5], é apresentada uma revisão abrangente sobre modelos de *machine learning* para previsão de séries temporais financeiras. O estudo aborda diversas técnicas e algoritmos utilizados na previsão de indicadores econômicos, fornecendo uma visão geral das abordagens mais eficazes e suas aplicações.

Esses trabalhos oferecem contribuições significativas para a área de previsão econômica utilizando redes neurais artificiais, abrangendo diferentes enfoques e metodologias para melhorar a precisão e a eficácia das previsões econômicas.

III. METODOLOGIA

Para realizar a previsão do Produto Interno Bruto (PIB) em países da América do Sul, adotamos uma abordagem baseada em redes neurais artificiais, mais especificamente o modelo de *Perceptron Multicamadas* (MLP). A escolha das MLPs se deve à sua capacidade de aprendizado a partir de dados históricos e sua habilidade em capturar relações não lineares complexas nos dados econômicos.

A. DESCRIÇÃO DOS DADOS E FONTES

O conjunto de dados utilizado para o treinamento e teste do modelo foi coletado de fontes oficiais [11]. Após o tratamento inicial, a base de dados usada possuía 15 colunas de dados, incluindo o dado alvo (PIB). Essa base de dados, posteriormente ao processamento e análise foram selecionados duas colunas: "Utilização de água doce (% dos recursos internos)" e "Emissão de CO_2 (% toneladas métricas per capita)". A escolha foi baseada no mapa de calor visto na Figura 1.




Figura 1. Mapa de calor do banco de dados referente ao Brasil.

Os dados abrangeram um período de 21 anos (2000 a 2020), com dados anuais do PIB. Foi realizada uma análise cuidadosa dos dados para garantir sua qualidade e consistência, com tratamentos dos dados nulos e vazios. Além disso, os dados foram coletados para os 12 países da América do Sul (a Guiana Francesa não entrou por ser uma região administrativa da França, portanto não considerada um país).

Para o estudo inicial, concentramos nossas análises nos dados do Brasil, a fim de obter uma visão mais detalhada e específica sobre o cenário do país em questão.

B. PRÉ-PROCESSAMENTO DOS DADOS

Antes de alimentar os dados à rede neural, foram realizadas etapas de pré-processamento. Os dados foram divididos em três conjuntos: treino, validação e teste, utilizando a função `train_test_split` da biblioteca Scikit-learn. Em seguida, os dados de entrada (características X) foram normalizados utilizando o `MinMaxScaler` para colocá-los na mesma escala, melhorando o treinamento e desempenho da rede neural. Além disso, os dados de saída (y) também foram normalizados para estarem na mesma escala que os dados de entrada, visando a melhoria do treinamento. No final do código, após a predição usando o modelo treinado, os valores de saída são revertidos para a escala original usando o `scaler_y.inverse_transform`, para que possamos interpretar os resultados na unidade original da variável alvo. Vale notar que uma métrica personalizada, R_2 , também é utilizada para avaliar o desempenho do modelo durante o treinamento.

C. ARQUITETURA DA REDE NEURAL

Para evitar problemas de *overfitting* e avaliar a capacidade de generalização do modelo, dividimos o conjunto de dados em conjuntos de treinamento, validação e teste, utilizando a técnica de validação cruzada. A otimização dos hiperparâmetros da rede neural foi realizada por meio de uma busca sistemática utilizando a técnica de *Grid Search*.

A arquitetura da rede foi composta por quatro camadas: uma camada de entrada com 12 variáveis, uma camada oculta com 50 neurônios, uma segunda camada oculta com 15 neurônios e uma camada de saída com um único neurônio para prever o valor do PIB. Essa estrutura pode ser observada na Figura 2.

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 50)	150
dense_1 (Dense)	(None, 15)	765
dense_2 (Dense)	(None, 1)	16

=====
 Total params: 931
 Trainable params: 931
 Non-trainable params: 0

Figura 2. Resumo da arquitetura do modelo usado.

Para treinar o modelo, utilizamos o algoritmo de *backpropagation* com a função de ativação ReLU nas camadas ocultas e uma função de ativação linear na camada de saída. A função de perda utilizada foi o erro médio quadrático (MSE) para avaliar o desempenho do modelo durante o treinamento.

Por fim, realizamos experimentos com diferentes configurações da rede, ajustando os hiperparâmetros e analisando a convergência e o desempenho do modelo em relação aos dados de teste. Os resultados foram avaliados utilizando métricas de desempenho, como o erro absoluto médio (MAE), erro médio percentual (MAPE) e o coeficiente de determinação (R^2), para verificar a precisão das previsões e a capacidade de generalização do modelo.

IV. RESULTADOS E DISCUSSÃO

optamos por focar nossas análises exclusivamente nos dados do Brasil. Essa decisão foi tomada com o objetivo de adquirir uma compreensão mais aprofundada e específica sobre o contexto e as características do país em questão. Ao concentrarmos nossos esforços em um único país, pudemos fazer análises mais específicas para tal país.

No entanto, vislumbramos ampliar nossa pesquisa para incluir os demais países presentes no banco de dados. Ao abranger uma amostra mais ampla de países da América do Sul, poderemos comparar e contrastar diferentes realidades socioeconômicas, ambientais e demográficas, obtendo uma perspectiva regional mais abrangente. Essa expansão geográfica permitirá identificar semelhanças e diferenças entre os países, bem como entender o panorama geral da região.

Como podemos observar significativas diferenças no mapa de calor visto na Figura 3 do banco de dados referente à todos países da América do Sul ao comparar com a Figura 1, que apresenta apenas os dados do Brasil.




Figura 3. Mapa de calor do banco de dados.

Os resultados obtidos neste estudo usando o modelo de rede neural proposto apresentaram um desempenho promissor na tarefa de regressão. A arquitetura da rede neural, composta por duas camadas ocultas com ativações ReLU,

mostrou-se adequada para capturar as características complexas do conjunto de dados. O pré-processamento dos dados, incluindo a divisão em conjuntos de treino, validação e teste, juntamente com a normalização das características de entrada e saída, contribuiu para melhorar a convergência do treinamento e a generalização do modelo. As métricas de avaliação do modelo, incluindo o erro absoluto médio (MAE), o erro quadrático médio (MSE), o erro percentual absoluto médio (MAPE) e o coeficiente de determinação (R^2), demonstraram resultados satisfatórios no conjunto de teste.

A. ANÁLISE DOS RESULTADOS OBTIDOS

Pela figura 4 podemos observar a métrica MSE (Erro Quadrático Médio) durante o treinamento com validação. Por volta da época 50 jpa obteve uma estabilidade.




Figura 4. Gráfico de treino e validação com parâmetro de loss igual a MSE.

Agora fazendo uma análise para os dados de teste temos:

- 1) MAE: $1.76e+11$
- 2) MAPE: 14.56
- 3) R^2 : 0.89

V. CONSIDERAÇÕES FINAIS

A. CONCLUSÃO

Em conclusão, o trabalho foi capaz de demonstrar com sucesso o uso de redes neurais artificiais como uma abordagem útil e promissora para prever o Produto Interno Bruto dos países do Brasil, ressaltando a importância dessas redes de lidar com relacionamentos não lineares entre os dados e capturar interações complexas entre variáveis econômicas para previsões cada vez mais precisas de cada região. O resultado das métricas ainda não é ideal, mostrando que o estudo ainda precisa passar por melhorias.

Apesar do estudo ter focado no Brasil ele pode ser adaptado para os demais países, além de ter possibilidade de fazer correlação entre eles.

É importante ressaltar que a tarefa de prever o PIB desses países vai muito além da aplicação de modelos matemáticos e de uma ciência exata. As condições socioeconômicas de

cada país apresentam um caráter extremamente complexo e multifacetado que, apesar de ser analisado de forma não linear pela rede, ainda não é prevista com a acurácia necessária para ser utilizada de forma independente, sendo necessária uma análise criteriosa e um profundo conhecimento das especificidades de cada região. Dito isso, é necessário reconhecer o método proposto como suscetível a falhas e dependentes de um processamento cuidadoso dos dados e ajustes adequados dos hiperparâmetros.

A interpretação dos resultados também deve ser feita com cautela, considerando que os modelos não garantem causalidade, mas sim correlações. A colaboração interdisciplinar entre economistas, cientistas de dados e especialistas regionais é essencial para melhorar ainda mais os modelos e abordagens colocadas na previsão do PIB para os países sul-americanos. A melhoria contínua dos métodos de aprendizado de máquina, aliada a análises rigorosas e contextualizadas, permitirá, finalmente, progressos significativos na área.

Em suma, apesar do resultado satisfatório obtido nesse estudo, é crucial reconhecer as limitações inerentes ao lidar com dados não lineares. Ao enfrentar esses desafios com determinação e rigor, podemos utilizar a tecnologia a nosso favor, buscando promover um desempenho econômico mais sustentável na América do Sul.

B. CONTRIBUIÇÕES E APLICAÇÕES FUTURAS

Por fim, é possível afirmar que as rede neural artificial modelada para a previsão do PIB de países da América do Sul oferecem diversas contribuições e aplicações futuras que, indubitavelmente, tem capacidade de auxiliar no planejamento econômico desses países capturando relações não-lineares entre os indicadores econômicos utilizados desde que suas limitações sejam respeitadas e seus resultados não sejam analisados de forma independente considerando o fato de que os dados analisados não são provenientes de uma ciência exata e sim de um contexto socioeconômico específico de cada região. Com isso, podemos citar algumas dessas aplicações:

1. No momento em que as redes neurais estão prevendo um desempenho econômico futuro, elas podem ser usadas para detectar sinais de crises econômicas com antecedência, fornecendo aos governos a possibilidade de adotar medidas preventivas.
2. Empresas podem usar previsões do PIB para planejar suas operações, estoques, produção e investimentos, já que seu desempenho está diretamente ligado à situação socioeconômica do país em que está localizada.
3. Governos podem usar essas previsões para avaliar a eficácia de suas políticas econômicas atuais e planejar novas estratégias em caso de resultados insatisfatórios.
4. A comparação entre os resultados de diferentes países da América do Sul pode auxiliar na compreensão das relações econômicas globais e no benchmarking do desempenho econômico, visto que países que tiveram melhores desempenhos nas previsões podem ser utilizados como exemplo de conduta.

5. Investidores podem usar os resultados obtidos pelas redes neurais para avaliar oportunidades de negócios na região e tomar decisões de investimento cada vez mais realistas e palpáveis.

6. Redes neurais podem ser aplicadas para prever a recuperação econômica após uma crise, fornecendo insights valiosos para a reconstrução e o crescimento sustentável.

Referências

- [1] M. S. Portugal, L. G. L. Fernandes, and others, "Redes neurais artificiais e previsão de séries econômicas: uma introdução," *Nova Economia*, vol. 6, no. 1, 1996, pp. 51–73. Economics Department, Universidade Federal de Minas Gerais (Brazil).
- [2] S. Tuo, T. Chen, H. He, Z. Feng, Y. Zhu, F. Liu, and C. Li, "A regional industrial economic forecasting model based on a deep convolutional neural network and big data," *Sustainability*, vol. 13, no. 22, 2021, pp. 12789. MDPI.
- [3] J. M. Wu, M. H. Tsai, C. C. Cheng, and M. E. Wu, "Predict the trend of economic indicators in time series based on recurrent neural network combined with leading indicators," *Journal of Intelligent & Fuzzy Systems*, Preprint, 2022, pp. 1–11. IOS Press.
- [4] C. J. Lu, T. S. Lee, and C. C. Chiu, "Financial time series forecasting using independent component analysis and support vector regression," *Decision Support Systems*, vol. 47, no. 2, 2009, pp. 115–125. Elsevier.
- [5] Y. Tang, Z. Song, Y. Zhu, H. Yuan, M. Hou, J. Ji, C. Tang, and J. Li, "A survey on machine learning models for financial time series forecasting," *Neurocomputing*, vol. 512, 2022, pp. 363–380. Elsevier.
- [6] "The Atlas of Economic Complexity," [Online]. Disponível: <https://atlas.cid.harvard.edu/>.
- [7] A. G. Rossi, "Predicting stock market returns with machine learning," Georgetown University, 2018.
- [8] M. Abe and H. Nakayama, "Deep learning for forecasting stock returns in the cross-section," in *Advances in Knowledge Discovery and Data Mining: 22nd Pacific-Asia Conference, PAKDD 2018, Melbourne, VIC, Australia, June 3–6, 2018, Proceedings, Part I 22, 2018*, pp. 273–284. Springer.
- [9] P. H. Franses and K. van Griensven, "Forecasting exchange rates using neural networks for technical trading rules," *Studies in Nonlinear Dynamics & Econometrics*, vol. 2, no. 4, 1998, pp. 51–73. De Gruyter.
- [10] G. O. Young, "Synthetic structure of industrial plastics," in *Plastics*, 2nd ed., vol. 3, J. Peters, Ed. New York, NY, USA: McGraw-Hill, 1964, pp. 15–64.
- [11] DataBank, "World Development Indicators," Junho 2023. [Online]. Disponível: <https://databank.worldbank.org/source/world-development-indicators>.
- [12] BCB, "Estatísticas," Junho 2023. [Online]. Disponível: <https://www.bcb.gov.br/estatisticas>.
- [13] IMF, "IMF Data," 2022. [Online]. Disponível: <https://www.imf.org/en/Data>.
- [14] OECD, "The OECD & LAC," 2023. [Online]. Disponível: <https://www.oecd.org/latin-america/data/>.



TITO. L DHAYSE (M'23) nasceu em Conceição do Coité, Bahia, Brasil em 2000. Mudou-se para o Rio de Janeiro em 2019, ingressou em Engenharia Eletrônica e de Computação na Universidade Federal do Rio de Janeiro (UFRJ). Atualmente cursando o 6^o período.

De 2021 a 2022 atuou como estagiária em Engenharia Eletrônica e de Programação na empresa Pipeway Engenharia.

• • •